

Аналіз та прогнозування ймовірності затримки доставки замовлення

на основі логістичних параметрів та географічного розташування

Студент: Янов Богдан
Група: ІП-45
Спеціальність: 121 Інженерія програмного
забезпечення

Дисципліна: Аналіз даних в інформаційних системах
КПІ ім. Ігоря Сікорського
Київ, 2026

ФОКУС ЗАХИСТУ

ризик затримки

Мета, об'єкт і предмет дослідження

МЕТА

оцінити $P(\text{delay})$

побудувати та порівняти моделі, які прогнозують ймовірність доставки пізніше очікуваної дати

ОБ'ЄКТ

процес доставки

виконання замовлень в електронній комерції: покупець, продавець, товар, оплата, маршрут

ПРЕДМЕТ

моделі класифікації

методи інтелектуального аналізу даних для класифікації замовлень за ризиком затримки

Ключова ідея

- прогноз має спиратися лише на ознаки, доступні на момент оформлення або ранньої обробки замовлення
- фактична дата доставки та фактична затримка не входять до ознак моделі, щоб уникнути витоку цільової інформації
- результат моделі розглядається як ризиковий скоринг, а не як автоматичне операційне рішення

Формалізація задачі прогнозування

Вхідні дані

$$X = (x_1, x_2, \dots, x_n)$$

Ознаки описують товар, продавця, покупця, маршрут, оплату та часові параметри замовлення.

Модель

$$f(X) = P(y = 1 \mid X)$$

Потрібно оцінити ймовірність того, що замовлення належить до класу затримки.

Цільова змінна

$$y = 1, \text{ якщо } \text{delivery} > \text{estimated}$$

Затримка визначається порівнянням фактичної дати доставки з очікуваною датою доставки.

Принципове обмеження

- не використовуються `days_to_delivery`, `delivery_delay_days`, фактична дата доставки та дата передачі перевізнику
- ці поля застосовуються тільки для формування цільової змінної та описової статистики
- такий підхід імітує реальний сценарій прогнозу до завершення доставки

Джерело даних - Brazilian E-Commerce Public Dataset by Olist

МАСШТАБ

~100 тис.

замовлень бразильського маркетплейсу за 2016-2018 роки

ГРАНУЛЯРНІСТЬ

CSV-таблиці

замовлення, позиції, покупці, продавці, товари, платежі, відгуки, геолокація

ПЕРЕВАГА

логістичні дати


є фактичні й очікувані дати доставки, географія та товарні характеристики

Таблиця	Що використовується
orders	статуси, дата купівлі, фактична та очікувана доставка
order_items	товарні позиції, продавці, ціна, фрахт, shipping limit
customers / sellers	міста, штати, ZIP-prefix покупця і продавця
products / categories	категорія, вага, габарити, опис, фото
geolocation	координати ZIP-prefix для відстані між точками
payments	тип оплати, кількість платежів, сума оплати

Обмеження даних

- немає перевізника
- немає складу
- немає погоди
- немає поточного навантаження маршруту

Сховище даних і ETL використано як основу



Що було повторно використано

- SQLite-сховище Olist з попередньої лабораторної роботи
- stage-зона з сирими CSV-даними
- виміри покупців, продавців, товарів, категорій, локацій, дат і типів оплати
- фактові таблиці товарних позицій, платежів і відгуків
- новий скрипт курсової формує аналітичну вітрину на рівні замовлення

1 Extract

завантаження
CSV до stage-
таблиць

>

2 Transform

нормалізація дат,
категорій, штатів,
ZIP-prefix

>

3 Load

виміри та фактові
таблиці у SQLite

>

4 View

агрегація до рівня
замовлення для
моделей

Аналітична вибірка сформована на рівні замовлення

КІЛЬКІСТЬ ЗАМОВЛЕНЬ

96 476

до вибірки включено лише замовлення з відомою цільовою ознакою

КІЛЬКІСТЬ ПОЛІВ

49

після підготовки й побудови додаткових ознак

ЧАСТКА ЗАТРИМОК

8.11%

клас є рідкісним, тому ассигасу не може бути головною метрикою

МЕДІАННА ВІДСТАНЬ

434.9 км

між продавцем і покупцем у сформованій вибірці

Показник	Значення
Середня затримка серед запізнілих	9.55 дня
Медіанна затримка серед запізнілих	5.81 дня
Медіанна відстань для запізнілих	512.45 км
Медіанна відстань без затримки	427.22 км

Агрегація до рівня order_id

- товарні позиції агреговано за кількістю, сумою, вагою, габаритами та категорією
- платежі агреговано за сумою, кількістю платежів і типами оплати
- географію покупця і продавця перетворено на маршрутні та дистанційні ознаки


Побудовані ознаки покривають маршрут, товар, оплату і час

Група	Приклади ознак
Географічні	customer_state, seller_state, route_state_pair, distance_km, same_state
Логістичні	estimated_delivery_days, shipping_limit_days, day_of_week для очікуваної дати
Товарні	order_items_count, вага, габарити, об'єм, кількість фото, категорія
Вартісні	order_price_sum, freight_sum, total_item_value_sum, freight_to_price_ratio
Платіжні	payment_types, payment_count, payment_installments, payment_value
Часові	purchase_month, purchase_week_of_year, purchase_day_of_week

Контроль витоку даних

Не використовувалися як входи моделі: days_to_delivery, delivery_delay_days, фактична дата доставки клієнту, дата передачі перевізнику.

Цільова ознака суттєво незбалансована



ПОЗИТИВНИЙ КЛАС

8.11%

замовлення, доставлені пізніше очікуваної дати

НЕГАТИВНИЙ КЛАС



91.89%

доставлено вчасно або раніше очікуваної дати

Наслідок для оцінювання

- модель, яка майже завжди прогнозує 'без затримки', матиме високу accuracy
- для захисту важливіші recall, F1, balanced accuracy, ROC-AUC та average precision
- поріг класифікації підбирався на валідаційній вибірці

Географія впливає на ризик, але не пояснює його повністю




Інтерпретація

Медіанна відстань для запізнілих доставок становить 512.45 км проти 427.22 км для доставок без затримки. Водночас ризик залежить також від регіональної логістики, сезонності та операційних факторів.

Дані розділено хронологічно, щоб імітувати прогноз майбутнього

Вибірка	Кількість	Період	Призначення
Навчальна	67 533	2016-09-15 - 2018-04-15	оцінювання параметрів моделей
Валідаційна	9 647	2018-04-15 - 2018-05-26	підбір порогу за F1
Тестова	19 296	2018-05-26 - 2018-08-29	фінальне порівняння якості



Випадковий поділ міг би завищити якість, бо змішує минулі й майбутні замовлення.

Порівнювались лінійна модель і три деревні підходи

Логістична регресія

інтерпретована базова модель; оцінює ймовірність через логістичну функцію

Дерево рішень

послідовність правил поділу простору ознак; зрозуміле, але схильне до перенавчання

Випадковий ліс

ансамбль незалежних дерев; зменшує дисперсію через bagging

Градiєнтний бустинг

послідовний ансамбль слабких моделей; виправляє помилки попередніх ітерацій

У моделях застосовано ваги класів, оскільки позитивний клас затримок становить лише невелику частку вибірки.


Метрики обрано з урахуванням рідкісного класу затримки

Метрика	Що показує	Навіщо потрібна
Accuracy	частку всіх правильних прогнозів	лише довідково, бо клас незбалансований
Balanced accuracy	середній recall для обох класів	не дає домінувати класу 'без затримки'
Precision	частку справжніх затримок серед попереджень	оцінює кількість хибних спрацювань
Recall	частку знайдених фактичних затримок	важливо для раннього моніторингу ризику
F1	баланс precision і recall	використано для підбору порогу
ROC-AUC	якість ранжування за всіма порогоми	порівнює здатність відділяти класи
Average precision	площу під precision-recall кривою	особливо корисна для незбалансованих задач

Основні критерії в роботі: average precision, ROC-AUC, balanced accuracy та F1; accuracy не є головним критерієм.

Логістична регресія дала найкраще ранжування ризику


Модель	Поріг	Accuracy	Bal. acc.	Precision	Recall	F1	ROC-AUC	Avg. prec.
Логістична регресія	0.749	0.641	0.655	0.094	0.672	0.165	0.705	0.104
Гرادієнтний бустинг	0.485	0.790	0.534	0.071	0.247	0.111	0.652	0.078
Випадковий ліс	0.454	0.812	0.511	0.060	0.174	0.089	0.520	0.059
Дерево рішень	0.645	0.814	0.512	0.061	0.175	0.090	0.457	0.056



Ключовий висновок

- логістична регресія має найкращі ROC-AUC, average precision, balanced accuracy і F1
- деревні моделі мають вищу accuracy, але гірше знаходять клас затримки
- це означає, що доступні ознаки містять переважно лінійний сигнал


Найкраща модель знаходить більшість затримок, але має багато попереджень



Як читати результат

- модель корисна як ранній фільтр ризикових замовлень
- багато false positive означає, що її не можна використовувати для автоматичних штрафів
- практичний сценарій - черга моніторингу або уточнення очікуваної доставки для найбільш ризикових замовлень


Коефіцієнти показують, які ознаки змінюють log-odds затримки



Що означають коефіцієнти

- додатні коефіцієнти збільшують log-odds затримки
- від'ємні коефіцієнти зменшують прогнозований ризик
- серед сильних факторів є маршрути між штатами, штат покупця, тиждень року, типи оплати та категорії товарів
- ризик затримки формується не лише відстанню, а й регіональною логістичною структурою

Практичне застосування - ризиковий скоринг, не автоматичний вирок



Де модель може бути корисною

- пріоритезація ризикових замовлень у логістичному моніторингу
- раннє інформування клієнтів про можливі зміни строків
- порівняння маршрутів, регіонів і продавців за ризиком

Що обмежує точність

- немає даних про перевізника, склад і фактичний маршрут
- немає поточного навантаження логістичних центрів
- немає святкових днів, погоди та операційних інцидентів

Висновки

- 1 Сформовано аналітичну вибірку на рівні замовлення з 96 476 записів та 49 полів.
- 2 Частка затримок становить 8.11%, тому задача є незбалансованою.
- 3 Побудовано географічні, логістичні, товарні, вартісні, платіжні та часові ознаки без витоку даних.
- 4 Порівняно логістичну регресію, дерево рішень, випадковий ліс і градієнтний бустинг.
- 5 Найкращою стала логістична регресія: ROC-AUC = 0.705, average precision = 0.104, balanced accuracy = 0.655, recall = 0.672.
- 6 Доступні ознаки придатні для попереднього ризикового скорингу, але недостатні для високоточного прогнозу кожної затримки.

Дякую за увагу

Питання до захисту

Тема: прогнозування ймовірності затримки доставки замовлення на основі логістичних параметрів та географічного розташування