

Пошуковий аналіз даних

Мета

Ознайомитись з методами перевірки статистичних гіпотез. Після завершення цієї лабораторної роботи ви зможете:

- Досліджувати дані за допомогою візуалізацій
- Робити описовий аналіз
- Групувати дані для аналізу
- Знаходити зв'язок між ознаками
- Перевіряти гіпотези про значущість коефіцієнта кореляції та про вигляд закону розподілу
- Робити дисперсійний аналіз

Завдання, що оцінюються

1. Скачати дані із файлу, який зберегли наприкінці попередньої роботи (з виправленими помилками та заповненими пропусками). Записати дані у dataframe. Дослідити ознаки з метою виявлення зв'язку між ними, побудувавши їх візуалізації. Візуально оцініть наявність та силу зв'язку між ознаками.
2. Порахувати кореляцію між всіма кількісними ознаками
3. Побудувати діаграми розсіювання для кількісних ознак та 'CO2 emission'. Які кількісні ознаки можуть бути предикторами кількості викидів CO2?
4. Побудувати діаграму розмаху для 'CO2 emission' по регіонам.
5. Виконати дисперсійний аналіз для кількості викидів CO2, згрупувати дані по регіонам

Завдання #1:

Дослідити ознаки з метою виявлення зв'язку між ними, побудувавши їх візуалізації

Зчитую дані з файлу у датафрейм

```
In [13]: import pandas as pd
import numpy as np
from scipy import stats
import matplotlib.pyplot as plt
import seaborn as sns

%matplotlib inline

path = "data/clean_data.csv"
df = pd.read_csv(path)
df.head()
```

```
Out[13]:
```

	Country Name	Region	GDP per capita	Population	CO2 emission	Area	Density
0	Afghanistan	South Asia	561.778746	34656032.0	9809.225	652860.0	53.083405
1	Albania	Europe & Central Asia	4124.982390	2876101.0	5716.853	28750.0	100.038296
2	Algeria	Middle East & North Africa	3916.881571	40606052.0	145400.217	2381740.0	17.048902
3	American Samoa	East Asia & Pacific	11834.745230	55599.0	6501.591	200.0	277.995000
4	Andorra	Europe & Central Asia	36988.622030	77281.0	462.042	470.0	164.427660

Будую діаграми


```
In [14]: print(df.dtypes)

numeric_columns = df.select_dtypes(include="number").columns

fig, axes = plt.subplots(1, len(numeric_columns), figsize=(22, 4))
for ax, column in zip(axes, numeric_columns):
    sns.histplot(df[column], kde=True, ax=ax)
    ax.set_title(column)
plt.tight_layout()
plt.show()

sns.pairplot(df[numeric_columns], diag_kind="kde")
plt.show()
```

Country Name str
Region str
GDP per capita float64
Population float64
CO2 emission float64
Area float64
Density float64
dtype: object



Візуально оцінію наявність та силу зв'язку між ознаками.



Завдання #2:

Порахувати кореляцію між всіма кількісними ознаками

Рахую кореляцію між всіма кількісними ознаками

```
In [15]: correlation_matrix = df[numeric_columns].corr()  
correlation_matrix
```

```
Out[15]:
```


	GDP per capita	Population	CO2 emission	Area	Density
GDP per capita	1.000000	-0.042606	0.088426	0.112213	0.244801
Population	-0.042606	1.000000	0.804091	0.422970	-0.027724
CO2 emission	0.088426	0.804091	1.000000	0.551697	-0.023559
Area	0.112213	0.422970	0.551697	1.000000	-0.064908
Density	0.244801	-0.027724	-0.023559	-0.064908	1.000000

Завдання #3:

Побудувати діаграми розсіювання для кількісних ознак та 'CO2 emission'.
Візуально оцінити наявність та силу зв'язку між цими ознаками.

Будую діаграму розсіювання для кількісних ознак та 'CO2 emission'

```
In [16]: predictor_columns = [column for column in numeric_columns if column != "CO2  
  
fig, axes = plt.subplots(2, 2, figsize=(14, 10))  
for ax, column in zip(axes.ravel(), predictor_columns):  
    sns.regplot(x=column, y="CO2 emission", data=df, ax=ax, scatter_kws={"al  
    ax.set_title(f"{column} vs CO2 emission")  
plt.tight_layout()  
plt.show()
```



Які кількісні ознаки можуть бути предикторами кількості викидів CO₂? Population, Area

Обчислюю коефіцієнт кореляції Пірсона та P-value для всіх кількісних змінних та 'CO2 emission'

```
In [17]: pearson_results = []
for column in predictor_columns:
    pearson_coef, p_value = stats.pearsonr(df[column], df["CO2 emission"])
    pearson_results.append({
        "feature": column,
        "pearson_coef": pearson_coef,
        "p_value": p_value,
        "abs_pearson_coef": abs(pearson_coef),
    })

pearson_df = (
    pd.DataFrame(pearson_results)
    .sort_values("abs_pearson_coef", ascending=False)
    .drop(columns="abs_pearson_coef")
)
pearson_df
```

Out[17]:

	feature	pearson_coef	p_value
1	Population	0.804091	1.872255e-50
2	Area	0.551697	1.108550e-18
0	GDP per capita	0.088426	1.944190e-01
3	Density	-0.023559	7.300284e-01


Кількісні ознаки, які можуть бути предикторами кількості викидів CO2:

Population та **Area**. **Population** має сильну позитивну кореляцію з **C02 emission** (r приблизно 0.80, p -value < 0.001), а **Area** має помірну позитивну кореляцію (r приблизно 0.55, p -value < 0.001). **GDP per capita** і **Density** мають дуже слабкі кореляції та великі p -value, тому за цими даними не є хорошими лінійними предикторами викидів CO2.

Завдання #4:

Побудувати діаграму розмаху для 'CO2 emission' по регіонам.

```
In [18]: plt.figure(figsize=(14, 7))
sns.boxplot(x="Region", y="C02 emission", data=df)
plt.xticks(rotation=45, ha="right")
plt.title("C02 emission by Region")
plt.tight_layout()
plt.show()
```



Завдання #5:

Виконати дисперсійний аналіз для кількості викидів CO2, згрупувати дані по регіонам

Групую дані, щоб побачити чи впливає 'Region' на 'CO2 emission'.

```
In [19]: region_summary = (  
    df.groupby("Region")["CO2 emission"]  
    .agg(["count", "mean", "median", "std"])  
    .sort_values("mean", ascending=False)  
    )  
region_summary
```

```
Out[19]:
```

		count	mean	median	std
	Region				
	North America	3	1.930683e+06	537193.4980	2.890797e+06
	East Asia & Pacific	37	3.790087e+05	6501.5910	1.691324e+06
	South Asia	8	3.145543e+05	14101.4485	7.794037e+05
	Middle East & North Africa	21	1.262478e+05	60516.5010	1.770632e+05
	Europe & Central Asia	58	1.107782e+05	37487.7410	2.499820e+05
	Latin America & Caribbean	42	4.545107e+04	5881.8680	1.131925e+05
	Sub-Saharan Africa	48	1.700846e+04	2962.9360	7.118589e+04

Перевіряю розподіл даних в групах, щоб обрати вид дисперсійного аналізу.

```
In [20]: normality_results = []  
for region, group in df.groupby("Region"):  
    statistic, p_value = stats.shapiro(group["CO2 emission"])  
    normality_results.append({  
        "Region": region,  
        "count": len(group),  
        "Shapiro statistic": statistic,  
        "p_value": p_value,  
        "normal_distribution": p_value > 0.05,  
    })  
  
pd.DataFrame(normality_results).sort_values("p_value")
```

Out [20]:

	Region	count	Shapiro statistic	p_value	normal_distribution
6	Sub-Saharan Africa	48	0.215243	1.385671e-14	False
1	Europe & Central Asia	58	0.432444	1.252764e-13	False
0	East Asia & Pacific	37	0.224239	9.302523e-13	False
2	Latin America & Caribbean	42	0.441260	1.899448e-11	False
5	South Asia	8	0.472738	4.837927e-06	False
3	Middle East & North Africa	21	0.641445	5.577124e-06	False
4	North America	3	0.825726	1.775188e-01	True

Для отримання F-test score та P-value скористаюсь функцією `f_oneway` з модуля "stats", якщо розподіл даних в групах дозволяє застосувати класичний дисперсійний аналіз, або `kruskal` з модуля "stats" для непараметричного дисперсійного аналізу Краскела-Уоліса.

```
In [21]: region_groups = [group["CO2 emission"].values for _, group in df.groupby("Region")]
anova_result = stats.f_oneway(*region_groups)
kruskal_result = stats.kruskal(*region_groups)

print("ANOVA results: F=", anova_result.statistic, ", P =", anova_result.pvalue)
print("Kruskal-Wallis results: H=", kruskal_result.statistic, ", P =", kruskal_result.pvalue)
```

```
ANOVA results: F= 3.5481273710394987 , P = 0.0022846375299258107
Kruskal-Wallis results: H= 44.68739004201306 , P = 5.399605089980244e-08
```

Тест показує, що майже в усіх регіональних групах розподіл `CO2 emission` не є нормальним, тому для основного висновку використовую непараметричний тест Краскела-Уоліса. Результат із H приблизно 44.69 і P-value приблизно 5.40e-08 показує, що між регіонами є статистично значущі відмінності за викидами CO2. Але це не означає, що кожна пара регіонів значуще відрізняється між собою.

Розглянемо їх окремо.

```
In [22]: from itertools import combinations

pairwise_region_results = []
for region_a, region_b in combinations(sorted(df["Region"].unique()), 2):
    group_a = df.loc[df["Region"] == region_a, "CO2 emission"]
    group_b = df.loc[df["Region"] == region_b, "CO2 emission"]
    statistic, p_value = stats.kruskal(group_a, group_b)
    pairwise_region_results.append({
        "region_1": region_a,
        "region_2": region_b,
        "statistic": statistic,
        "p_value": p_value
    })
```

```
    "region_2": region_b,  
    "H_statistic": statistic,  
    "p_value": p_value,  
    "significant_0.05": p_value < 0.05,  
  })
```

```
pairwise_region_df = pd.DataFrame(pairwise_region_results).sort_values("H_st  
pairwise_region_df
```

Out [22]:

	region_1	region_2	H_statistic	p_value	significant_0.05
10	Europe & Central Asia	Sub-Saharan Africa	32.853400	9.937709e-09	True
17	Middle East & North Africa	Sub-Saharan Africa	27.483673	1.584263e-07	True
11	Latin America & Caribbean	Middle East & North Africa	15.158613	9.884638e-05	True
6	Europe & Central Asia	Latin America & Caribbean	13.344529	2.591776e-04	True
2	East Asia & Pacific	Middle East & North Africa	7.344991	6.724986e-03	True
0	East Asia & Pacific	Europe & Central Asia	5.419991	1.990747e-02	True
20	South Asia	Sub-Saharan Africa	5.158443	2.313363e-02	True
13	Latin America & Caribbean	South Asia	2.438846	1.183633e-01	False
7	Europe & Central Asia	Middle East & North Africa	2.146727	1.428742e-01	False
12	Latin America & Caribbean	North America	1.990960	1.582406e-01	False
3	East Asia & Pacific	North America	1.715212	1.903106e-01	False
19	North America	Sub-Saharan Africa	1.641026	2.001848e-01	False
16	Middle East & North Africa	South Asia	1.609524	2.045588e-01	False
14	Latin America & Caribbean	Sub-Saharan Africa	1.561513	2.114438e-01	False
4	East Asia & Pacific	South Asia	1.142487	2.851275e-01	False
5	East Asia & Pacific	Sub-Saharan Africa	1.094030	2.955800e-01	False
8	Europe & Central Asia	North America	1.069956	3.009555e-01	False
15	Middle East & North Africa	North America	0.550476	4.581232e-01	False
18	North America	South Asia	0.375000	5.402914e-01	False
9	Europe & Central Asia	South Asia	0.186961	6.654580e-01	False

	region_1	region_2	H_statistic	p_value	significant_0.05
1	East Asia & Pacific	Latin America & Caribbean	0.021722	8.828295e-01	False

Додаткове завдання:

Дайте відповіді на питання

1. По результатам дисперсійного аналізу для кількості викидів CO2 по регіонам, вкажіть пару регіонів, що відрізняються найсильніше.
2. Створіть якісну ознаку 'Rich country', згрупувавши дані 'GDP per capita' в кілька категорій (багаті-бідні країни, 3-5 категорій). Побудуйте діаграму розмаху для 'CO2 emission' по категоріям 'Rich country'. Візуально оцініть наявність зв'язку між цими ознаками.
3. Виконайте дисперсійний аналіз для 'CO2 emission', згрупувавши дані по категоріям 'Rich country'.

► Висновок до додаткового завдання

```
In [23]: # 1. Пара регіонів, що відрізняється найсильніше за тестовою статистикою
strongest_region_difference = pairwise_region_df.iloc[0]
print("Найсильніша відмінність:")
print(strongest_region_difference)

# 2. Створення якісної ознаки Rich country на основі квантилів GDP per capita
df["Rich country"] = pd.qcut(
    df["GDP per capita"],
    q=4,
    labels=["low income", "lower middle income", "upper middle income", "high income"]
)

plt.figure(figsize=(10, 6))
sns.boxplot(x="Rich country", y="CO2 emission", data=df)
plt.title("CO2 emission by Rich country category")
plt.tight_layout()
plt.show()

rich_summary = (
    df.groupby("Rich country", observed=True)["CO2 emission"]
    .agg(["count", "mean", "median", "std"])
)
print("\nЧислова статистика за категоріями Rich country:")
print(rich_summary)

# 3. Дисперсійний аналіз для CO2 emission за категоріями Rich country
```

```

rich_groups = [group["CO2 emission"].values for _, group in df.groupby("Rich country")]

print("\nПеревірка нормальності в категоріях Rich country:")
for category, group in df.groupby("Rich country", observed=True):
    statistic, p_value = stats.shapiro(group["CO2 emission"])
    print(category, "Shapiro statistic=", statistic, "P=", p_value)

rich_anova_result = stats.f_oneway(*rich_groups)
rich_kruskal_result = stats.kruskal(*rich_groups)

print("\nANOVA results for Rich country: F=", rich_anova_result.statistic, "P=", rich_anova_result.pvalue)
print("Kruskal-Wallis results for Rich country: H=", rich_kruskal_result.statistic, "P=", rich_kruskal_result.pvalue)

print("\nПарні порівняння Rich country:")
pairwise_rich_results = []
for category_a, category_b in combinations(df["Rich country"].cat.categories, 2):
    group_a = df.loc[df["Rich country"] == category_a, "CO2 emission"]
    group_b = df.loc[df["Rich country"] == category_b, "CO2 emission"]
    statistic, p_value = stats.kruskal(group_a, group_b)
    pairwise_rich_results.append({
        "category_1": category_a,
        "category_2": category_b,
        "H_statistic": statistic,
        "p_value": p_value,
        "significant_0.05": p_value < 0.05,
    })


pairwise_rich_df = pd.DataFrame(pairwise_rich_results).sort_values("H_statistic")
pairwise_rich_df

```

Найсильніша відмінність:

region_1	Europe & Central Asia
region_2	Sub-Saharan Africa
H_statistic	32.8534
p_value	0.0
significant_0.05	True

Name: 10, dtype: object



Описова статистика за категоріями Rich country:

	count	mean	median	std
Rich country				
low income	55	56287.116545	4503.076	3.018455e+05
lower middle income	54	66362.853426	16846.198	1.323162e+05
upper middle income	55	276636.879891	7033.306	1.398172e+06
high income	53	230926.142321	45052.762	7.400130e+05

Перевірка нормальності в категоріях Rich country:

low income Shapiro statistic= 0.16833207850422915 P= 5.087697472242454e-16
lower middle income Shapiro statistic= 0.5451401783042596 P= 1.0994857994781772e-11
upper middle income Shapiro statistic= 0.18655980793189275 P= 7.484587402592949e-16
high income Shapiro statistic= 0.29822711072817887 P= 1.7136364560431865e-14

ANOVA results for Rich country: F= 1.0548547427542572 , P = 0.369271163594553

Kruskal-Wallis results for Rich country: H= 23.559036898326372 , P = 3.087602342206974e-05

Парні порівняння Rich country:

Out[23]:

	category_1	category_2	H_statistic	p_value	significant_0.05
2	low income	high income	23.184421	0.000001	True
5	upper middle income	high income	7.975114	0.004742	True
4	lower middle income	high income	6.734892	0.009454	True
0	low income	lower middle income	6.541285	0.010540	True
1	low income	upper middle income	2.576541	0.108458	False
3	lower middle income	upper middle income	0.206635	0.649418	False

Виконав студент групи ІП-45
Янов Богдан